

## **ALGUNOS EJEMPLOS DE DISTRIBUCIONES**

ALAN REYES-FIGUEROA

INTRODUCCIÓN A LA CIENCIA DE DATOS

(AULA 07) 30.ENERO.2021

# Variables aleatorias discretas

- distribución Uniforme  $U[a..b]$ ,
- distribución Bernoulli  $Ber(p)$ ,
- distribución Binomial  $Binom(n, p)$ ,
- distribución Geométrica  $Geom(p)$ ,
- distribución Poisson  $Poisson(\lambda)$ ,
  
- distribución Rademacher  $Rad(p)$ ,
- distribución Binomial Negativa  $NB(r, p)$ ,
- distribución Hipergeométrica  $Hypergeometric(N, K, n)$ .


# Variables aleatorias discretas

## 1. Distribución Uniforme

$$X \sim U[a..b] \Leftrightarrow \mathbb{P}(X = k) = \frac{1}{b-a+1}, \text{ para } k = a, a+1, \dots, b.$$

### Obs.

- Esta distribución depende de dos parámetros (de localización):  $a$  y  $b$ .
- El caso  $a = b$ , con  $\mathbb{P}(X = a = b) = 1$  se llama una v.a. *degenerada*.




# Variables aleatorias discretas

## 2. Distribución Bernoulli

$$X \sim \text{Ber}(p) \Leftrightarrow \mathbb{P}(X = 1) = p, \mathbb{P}(X = 0) = 1 - p, \text{ para } 0 \leq p \leq 1.$$

### Obs.

- La distribución es simétrica si, y sólo si,  $p = 1/2$ .
- $\mathbb{E}(X) = p$ ,  $\text{Var}(X) = p(1 - p)$ .



# Variables aleatorias discretas

La distribución Bernoulli tiene una hermana gemela: la distribución de Rademacher.

$$X \sim \text{Rad}(p) \Leftrightarrow \mathbb{P}(X = 1) = p, \mathbb{P}(X = -1) = 1 - p, \text{ para } 0 \leq p \leq 1.$$

## Preguntas:

- ¿Cuál es la media y varianza de la distribución  $\text{Rad}(p)$ .
- Sean  $X, Y$  v.a., con  $X \sim \text{Ber}(p)$  y  $Y \sim \text{Rad}(p)$ . Escribir  $X$  en términos de  $Y$ , y  $Y$  en términos de  $X$ .

La distribución de Bernoulli es importante para escribir situaciones donde se cuenta la ocurrencia de eventos. La variable  $X \sim \text{Ber}(p)$  cuenta o indica la ocurrencia del evento de interés.

# Variables aleatorias discretas

## 3. Distribución Binomial


$$X \sim \text{Binom}(n, p) \Leftrightarrow \mathbb{P}(X = k) = \binom{n}{k} p^k (1-p)^{n-k}, \text{ para } k = 0, 1, \dots, n.$$

Interpretación: Si  $\{X_i\}_{i=1}^n$  son v.a. i.i.d. con  $X_i \sim \text{Ber}(p)$ , entonces

$$X = \sum_{i=1}^n X_i \sim \text{Binom}(n, p).$$

### Obs.

- La distribución es simétrica si, y sólo si,  $p = 1/2$ .
- $\mathbb{E}(X) = np$ ,  $\text{Var}(X) = np(1-p)$ .



# Variables aleatorias discretas


## 4. Distribución Geométrica

$$X \sim \text{Geom}(n, p) \Leftrightarrow \mathbb{P}(X = k) = p(1 - p)^{k-1}, \text{ para } k = 1, 2, 3, \dots$$

Interpretación: Si  $\{X_i\}_{i=1}$  son v.a. *i.i.d.* con  $X_i \sim \text{Ber}(p)$ , entonces  
 $X = \text{el momento del primer éxito en } \{X_i\} \sim \text{Geom}(p)$ .

### Obs.

- La probabilidad va decayendo en forma geométrica con  $k$ .
- $\mathbb{E}(X) = \frac{1}{p}$ .



# Variables aleatorias discretas

## 5. Distribución Poisson


$$X \sim \text{Poisson}(\lambda) \Leftrightarrow \mathbb{P}(X = k) = \frac{e^{-\lambda} \lambda^k}{k!}, \text{ para } k = 0, 1, 2, \dots$$

Interpretación: Si  $\{X_i\}_{i=1}$  son v.a. i.i.d. con  $X_i \sim \text{Ber}(p)$ , entonces

$X$  = el momento del primer éxito en  $\{X_i\} \sim \text{Geom}(p)$ .

### Obs.

- Cuenta el número de llegadas de un proceso con tiempos exponenciales  $\text{Exp}(\lambda)$ .
- $\mathbb{E}(X) = \lambda$ . Representa el número esperado de veces que ocurra el fenómeno durante un intervalo dado.





# Variables aleatorias continuas

- distribución Uniforme  $U[a..b]$ ,
- distribución Normal  $\mathcal{N}(\mu, \sigma^2)$ ,
- distribución Lognormal  $\mathcal{LN}(\mu, \sigma^2)$ ,
  
- distribución Exponencial  $Exp(\lambda)$ ,
- distribución Erlang  $Erlang(n, \lambda)$ ,
- distribución Gamma  $\Gamma(\alpha, \beta)$ ,
- distribución Beta  $Beta(\alpha, \beta)$ ,
  
- distribución Weibull,
- distribución Pareto,
- distribuciones de valores extremos.

# Variables aleatorias continuas

## 1. Distribución Uniforme

$$X \sim U[a..b] \Leftrightarrow f_X(t) = \frac{1}{b-a} \mathbf{1}_{[a,b]}(t).$$

**Obs.** Aquí la función  $\mathbf{1}_{[a,b]}$  es una *función indicadora* o *función característica*, que indica cuál es el soporte de la distribución.

Recordemos que para cualquier subconjunto  $A \subseteq \mathbb{R}$

$$\mathbf{1}_A(t) = \begin{cases} 1, & t \in A; \\ 0, & t \notin A. \end{cases}$$

Preguntas: ¿Cuál es la función de distribución  $F_X$ ? ¿ $\mathbb{E}(X)$ ,  $\text{Var}(X)$ ?

2. Distribución Exponencial Dado un parámetro  $\lambda > 0$ , la distribución exponencial tiene densidad

$$f_X(t) = \lambda e^{-\lambda t} \mathbf{1}_{[0, \infty)}(t), \quad F_X(t) = (1 - e^{-\lambda t}) \mathbf{1}_{[0, \infty)}(t).$$

**Obs.**

- $\mathbb{E}(X) = \frac{1}{\lambda}$  y  $\text{Var}(X) = \frac{1}{\lambda^2}$ .
- En ocasiones, se parametriza en términos de su valor esperado  $\theta = \frac{1}{\lambda}$ :

$$f_X(t) = \frac{1}{\theta} e^{-t/\theta} \mathbf{1}_{[0, \infty)}(t).$$

# Variables aleatorias continuas


3. Distribución Normal Dados dos parámetros  $\mu \in \mathbb{R}$ ,  $\sigma > 0$ , la distribución normal tiene densidad

$$f_X(t) = \frac{1}{(2\pi\sigma^2)^{1/2}} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right) \mathbf{1}_{\mathbb{R}}(t).$$

**Obs.**

- $\mathbb{E}(X) = \mu$  y  $\text{Var}(X) = \sigma^2$ .
- La distribución es simétrica alrededor de  $\mu$ .
- $X$  no tiene una función de distribución elemental

$$F_X(x) = \int_{-\infty}^x f_X(t) dt.$$



## Propiedades

1. Si  $X \sim \mathcal{N}(\mu, \sigma^2)$ , se tiene que  $Z = \frac{X-\mu}{\sigma} \sim \mathcal{N}(, 1)$ .
2. Si  $X_1 \sim \mathcal{N}(\mu_1, \sigma_1^2)$  y  $X_2 \sim \mathcal{N}(\mu_2, \sigma_2^2)$ , y  $X_1, X_2$  son independientes, entonces

$$X_1 + X_2 \sim \mathcal{N}(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$$

3. Si  $X \sim \mathcal{N}(\mu, \sigma^2)$ , se tiene que  $-X \sim \mathcal{N}(-\mu, \sigma^2)$ .
4. En general, si  $X \sim \mathcal{N}(\mu, \sigma^2)$ , y  $a, b \in \mathbb{R}$ , entonces  $Y = aX + b$  es normal, con

$$Y \sim \mathcal{N}(a\mu + b, a^2\sigma^2).$$

# Teoremas importantes

## Teorema (Desigualdad de Markov)

Si  $X$  es una v.a. no-negativa,  $a > 0$ , entonces

$$\mathbb{P}(X \geq a) \leq \frac{\mathbb{E}(X)}{a}.$$

## Teorema (Desigualdad de Tchebyshev)

Si  $X$  es una v.a. con  $\mathbb{E}(X)$  y  $\text{Var}(X)$  finitas,  $a > 0$ , entonces

$$\mathbb{P}(|X - \mathbb{E}(X)| \geq a) \leq \frac{\text{Var}(X)}{a^2}.$$

# Teoremas importantes

## Teorema (Ley débil de los números grandes)

Sean  $X_1, X_2, \dots, X_n$  variables aleatorias i.i.d., con  $\mathbb{E}(X_i) < \infty$ . Entonces, para todo  $\epsilon > 0$


$$\lim_{n \rightarrow \infty} \mathbb{P}\left(\left|\frac{X_1, X_2, \dots, X_n}{n} - \mathbb{E}(X)\right| > \epsilon\right) = 0.$$

### Interpretación:

Se repite el experimento  $n$  veces, con resultados  $X_i$ .

$\mathbb{E}(X) = \mathbb{P}(A)$ , entonces  $\frac{X_1, X_2, \dots, X_n}{n}$  es el porcentaje de veces que ocurrió  $A$ .

La ley débil dice que el porcentaje de veces  $A$  ocurrió en  $n$  repeticiones se aproxima a  $\mathbb{E}(X)$ .



# Teoremas importantes

## Teorema (Teorema Central de Límite)

Sean  $X_1, X_2, \dots, X_n$  variables aleatorias i.i.d., con  $\mathbb{E}(X_i) = \mu$ ,  $\text{Var}(X_i) = \sigma^2$  finitas. Entonces


$$\lim_{n \rightarrow \infty} \mathbb{P}\left(\frac{S_n/n - \mu}{\sigma^2/\sqrt{n}} \leq x\right) = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}} e^{-t^2/2} dt.$$

### Consecuencias:

$$\frac{S_n}{n} \sim \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right),$$

o equivalentemente

$$X_1 + \dots + X_n = S_n \sim \mathcal{N}(n\mu, n\sigma^2).$$





# Distribuciones multivariadas

Sea  $X = (X_1, X_2, \dots, X_d) \in \mathbb{R}^d$  un vector aleatorio (esto es, cada componente  $X_i$  es una variable aleatoria  $X_i: \Omega \rightarrow \mathbb{R}$ ).

## Definición

Definimos el **valor esperado** de  $X$  como el vector  $\mu \in \mathbb{R}^d$  dado por

$$\mathbb{E}(X) = \mu = (\mu_1, \mu_2, \dots, \mu_d)^T \in \mathbb{R}^d,$$

donde  $\mu_i = \mathbb{E}(X_i)$ , para  $i = 1, 2, \dots, d$ .

## Definición

Definimos la **varianza** de  $X$  como la matriz  $\Sigma \in \mathbb{R}^{d \times d}$  dada por

$$\text{Var}(X) = \Sigma = (\text{Cov}(X_i, X_j))_{i,j}.$$

La entrada  $(i, j)$  de esta matriz corresponde a la covarianza de las variables  $X_i$  y  $X_j$ . A  $\Sigma$  también se le conoce como la **matriz de covarianza** de  $X$ .

## Propiedades

Para cualquier vector aleatorio  $X \in \mathbb{R}^d$ , la matriz de covarianzas  $\Sigma = \text{Var}(X)$  satisface

1.  $\Sigma$  es simétrica (como consecuencia, tiene autovalores reales).
2.  $\Sigma$  es semi-definida positiva (todos sus autovalores son no-negativos). En particular, para todo vector  $\mathbf{x} \in \mathbb{R}^d$ , se cumple que  $\mathbf{x}^T \Sigma \mathbf{x} \geq 0$ .
3. La diagonal de  $\Sigma$  contiene a las varianzas  $\sigma_i^2 = \text{Var}(X_i)$ , para  $i = 1, 2, \dots, d$ .

# Distribuciones multivariadas

Sea  $X_1, X_2, \dots, X_n \in \mathbb{R}^d$  es una muestra aleatoria de vectores i.i.d (independientes e idénticamente distribuidos), todos con distribución  $X$ . Podemos codificar esta muestra dentro de una matriz,  $\mathbb{X} \in \mathbb{R}^n \times \mathbb{R}^d$ , llamada la **matriz de datos** (cada dato de la muestra es un renglón de  $\mathbb{X}$ ).

$$\mathbb{X} = \begin{pmatrix} X_{11} & X_{12} & \dots & X_{1d} \\ X_{21} & X_{22} & \dots & X_{2d} \\ \vdots & \vdots & \ddots & \vdots \\ X_{n1} & X_{n2} & \dots & X_{nd} \end{pmatrix},$$

donde

$$X_i = (x_{i1}, x_{i2}, \dots, x_{id}) \in \mathbb{R}^d, \quad i = 1, 2, \dots, n.$$

# Distribuciones multivariadas

Observe que la  $i$ -ésima columna de  $\mathbb{X}$  corresponde a una muestra (de tamaño  $n$ ) de la variable aleatoria  $X_i$ . Podemos entonces restar a cada columna su correspondiente media  $\mu_i = \mathbb{E}(X_i)$ . Así, obtenemos una versión centrada de la matriz de datos:

$$\mathbb{X}_c = \mathbb{X} - \mu = \begin{pmatrix} X_{11} - \mu_1 & X_{12} - \mu_2 & \dots & X_{1d} - \mu_d \\ X_{21} - \mu_1 & X_{22} - \mu_2 & \dots & X_{2d} - \mu_d \\ \vdots & \vdots & \ddots & \vdots \\ X_{n1} - \mu_1 & X_{n2} - \mu_2 & \dots & X_{nd} - \mu_d \end{pmatrix}.$$

Es posible mostrar (con las propiedades de la página siguiente) que la matriz de covarianzas empírica (muestral) se puede escribir como

$$\Sigma = \text{Var}(X) = \mathbb{X}_c^T \mathbb{X}_c.$$

## Propiedades

Sea  $X, Y \in \mathbb{R}^d$  vectores aleatorios,  $a, b \in \mathbb{R}$ ,  $c \in \mathbb{R}^d$  constantes,  $A \in \mathbb{R}^{p \times d}$  una matriz constante. Entonces

1.  $\mathbb{E}(aX + bY) = a\mathbb{E}(X) + b\mathbb{E}(Y)$ ,
2.  $\mathbb{E}(c) = c$ ,
3.  $\mathbb{E}(\mathbb{E}(X)) = \mathbb{E}(X)$ ,
4.  $\text{Var}(aX) = a^2\text{Var}(X)$ ,
5.  **$\text{Var}(\mathbf{AX}) = \mathbf{A}^T \text{Var}(\mathbf{X}) \mathbf{A}$** ,
6.  $\text{Var}(aX + bY) = a^2\text{Var}(X) + b^2\text{Var}(Y) + 2ab\text{Cov}(X, Y)$ ,
7. Si  $X \perp Y$ , entonces  $\text{Cov}(X, Y) = 0$ ,
8. Si  $X \perp Y$ , entonces  $\text{Var}(aX + bY) = a^2\text{Var}(X) + b^2\text{Var}(Y)$ .

# Distribución normal multivariada

Sea  $X = (X_1, X_2, \dots, X_d) \in \mathbb{R}^d$  un vector aleatorio. Decimos que  $X$  sigue una **distribución normal multivariada**  $\mathcal{N}_d(\mu, \Sigma)$  si su densidad está dada por

$$f_X(\mathbf{x}) = \int_{\mathbb{R}^d} \frac{1}{(2\pi)^{d/2} \sqrt{|\Sigma|}} \exp\left(-\frac{1}{2}(\mathbf{x} - \mu)^T \Sigma^{-1}(\mathbf{x} - \mu)\right) d\mathbf{x}.$$



Aquí,

$$\mathbb{E}(X) = \mu = (\mu_1, \mu_2, \dots, \mu_d)^T,$$

y

$$\text{Var}(X) = \Sigma = \begin{pmatrix} \text{Cov}(X_1, X_1) & \text{Cov}(X_1, X_2) & \dots & \text{Cov}(X_1, X_d) \\ \text{Cov}(X_2, X_1) & \text{Cov}(X_2, X_2) & \dots & \text{Cov}(X_2, X_d) \\ \vdots & \vdots & \ddots & \vdots \\ \text{Cov}(X_d, X_1) & \text{Cov}(X_d, X_2) & \dots & \text{Cov}(X_d, X_d) \end{pmatrix}.$$

# Distribución normal multivariada



Densidad de una normal bivariada: (a) como nube de puntos, (b) como función.

# Distribución normal multivariada


Típicamente la matriz  $\Sigma$  proporciona información sobre la relación entre las variables componentes.

$Cov(X) = [Cov(X_i, X_j)]$  es una matriz simétrica y pos. definida.

Caso  $d = 2$ :

$$\begin{pmatrix} Var(X_1) & Cov(X_1, X_2) \\ Cov(X_1, X_2) & Var(X_2) \end{pmatrix} = \begin{pmatrix} \sigma_{X_1}^2 & Cor(X_1, X_2)\sigma_{X_1}\sigma_{X_2} \\ Cor(X_1, X_2)\sigma_{X_1}\sigma_{X_2} & \sigma_{X_2}^2 \end{pmatrix}$$

Cambiar  $\rho = Cor(X_1, X_2)$ :




<http://personal.kenyon.edu/hartlaub/MellonProject/images/Bivariate52.gif>.



# Distribución normal multivariada

Una forma práctica de ver esta información de covarianza o correlación entre las componentes es a través de *pair-plots*.



Pairplot de una muestra para una normal 3-variada.

# Distribución normal multivariada

Problema: ¿Cómo generar una muestra de una distribución normal  $d$ -variada con  $\mu$  y  $\Sigma$  específicas?

Algoritmo (o receta):

1. Generar  $d$  muestras (de tamaño  $n$ ), independientes, de distribuciones normales estándar  $Z_1, Z_2, \dots, Z_d \in \mathbb{R}^n$ , y construir una matriz de datos  $\mathbb{Z}$  con las muestras  $Z_i$  como columnas.

Como son independientes y estándar el vector  $Z = (Z_1, \dots, Z_d)$  sigue una distribución normal estándar  $\mathcal{N}_d(\mathbf{0}, I_d)$ .

2. Asegurarse que la matriz  $\Sigma$  es simétrica y positiva definida. Luego, construir descomposición de Cholesky  $L^T L = \Sigma$ , (el algoritmo que vieron en análisis numérico).

3. Construir la variable aleatoria  $X = LZ + \mu$ , la cual tiene una matriz de datos dada por  $\mathbb{X} = L\mathbb{Z} + \mu$  (la muestra que queremos). De las propiedades anteriores, tenemos que  $\mathbb{E}(Z) = \mu$  y  $\text{Var}(X) = L^T I_d L = L^T L = \Sigma$ .